PROJET 9 — DATA ANALYST

Analysez et anticipez les tendances du streaming musical

Comité éditorial MeloWave · Analyse du catalogue et prévision d'activité

Mission 1 — Analysez le catalogue Mission 2 — Prévoyez l'activité d'un genre

CONTEXTE

Deux demandes, une même démarche

MISSION 1 — Analyser le catalogue

114 000 morceaux, 114 genres, 20 variables audio.
Auditer, décrire, et répondre à trois questions du comité par des tests statistiques.

MISSION 2 — Prévoir l'activité d'un genre

9,8 millions de lignes de classements Top 200, 2017-2020.
Prévoir la présence de la Pop à 6 mois, et qualifier la fiabilité de cette prévision.

1 **Auditer**
Manquants, doublons, valeurs impossibles

2 **Décrire**
Distributions, classements, profils

3 **Tester**
Trois familles de tests

4 **Construire**
Série quotidienne, diagnostic des trous

5 **Modéliser**
Prophet, backtest, validation croisée

6 **Conclure**
Prévision, limites, recommandations

Un principe commun : aucune décision n'est appliquée sans être écrite et justifiée, et aucun modèle n'est retenu sans être comparé à une référence simple.

MISSION 1 — ÉTAPE 1

Le nettoyage : distinguer l'erreur de la caractéristique

450 doublons stricts → supprimés

Lignes identiques sur les 20 colonnes, genre compris. Erreur d'ingestion : la même information comptée deux fois.

16 299 track_id multi-genres → conservés

Un même morceau rattaché jusqu'à 9 genres. Ce n'est pas un défaut : c'est la maille du jeu de données.

La preuve qui tranche : toutes les caractéristiques audio sont strictement identiques d'une occurrence à l'autre d'un même morceau. Il ne s'agit pas de morceaux différents.

df_genres — 113 549 lignes

Maille (morceau × genre) : toute comparaison entre genres.

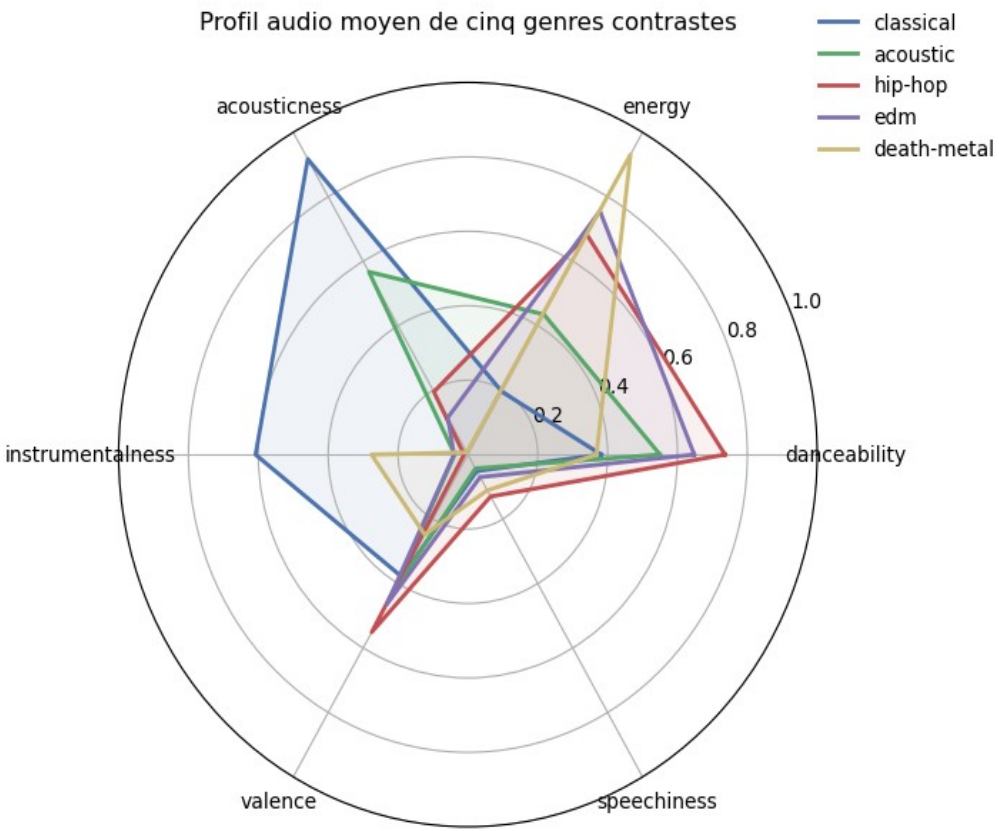
df_tracks — 89 740 morceaux

Maille morceau unique : distributions, classements, corrélations.

Une seule table ne peut pas servir les deux usages : sans déduplication, 18 % des morceaux pèseraient jusqu'à 9 fois leur poids réel dans les distributions du catalogue. · *Bilan du nettoyage : 114 000 → 113 549 lignes, soit 0,40 % de perte.*

MISSION 1 — ÉTAPE 2

Ce que révèle la description du catalogue



Le profil sonore distingue les genres

acousticness, instrumentalness et speechiness portent l'information. valence ne discrimine pas : tous les genres s'y tiennent dans une bande étroite.

Un échantillon stratifié

Exactement 1 000 morceaux par genre, écart-type nul.
→ Comparer les genres est légitime ; conclure sur leur présence relative ne l'est pas.

14,1 %

des morceaux ont une popularité de 0 — « aucune écoute récente », pas une donnée manquante

16 / 20

des 20 premiers artistes n'ont qu'un seul morceau si l'on classe par moyenne sans seuil

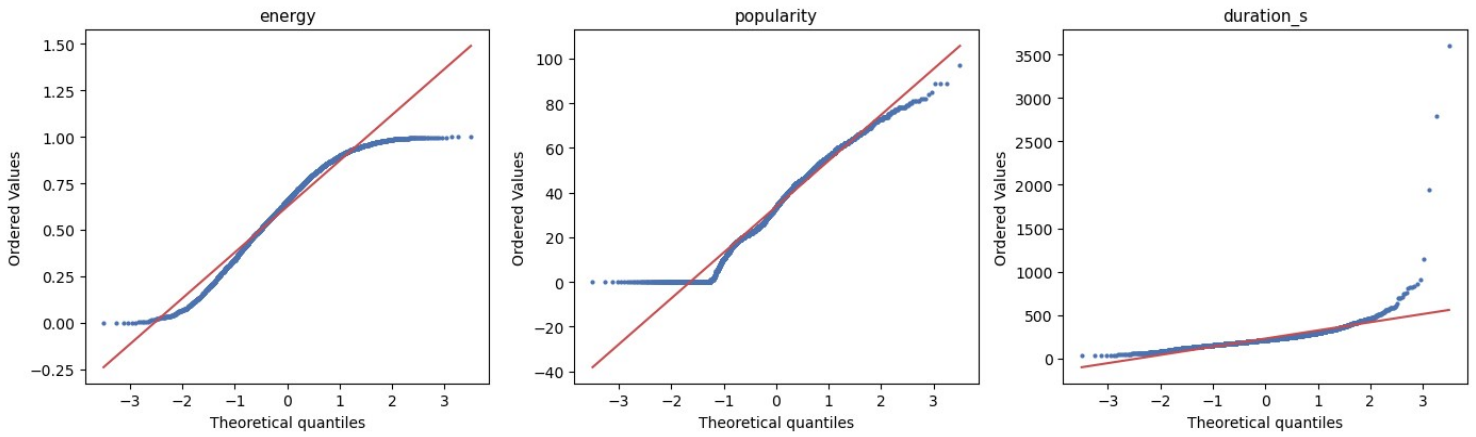
≥ 10

morceaux exigés au classement, après éclatement des featurings

MISSION 1 — ÉTAPE 3

Vérifier avant de tester

Pearson et l'ANOVA supposent des données approximativement normales. Un test appliqué sans vérifier ses conditions ne prouve rien : il fallait trancher avant de choisir.



Droites de Henry : les points s'écartent de la droite théorique, surtout aux extrémités.

Shapiro-Wilk

0 variable sur 11 ne suit une loi normale (α = 0,05).

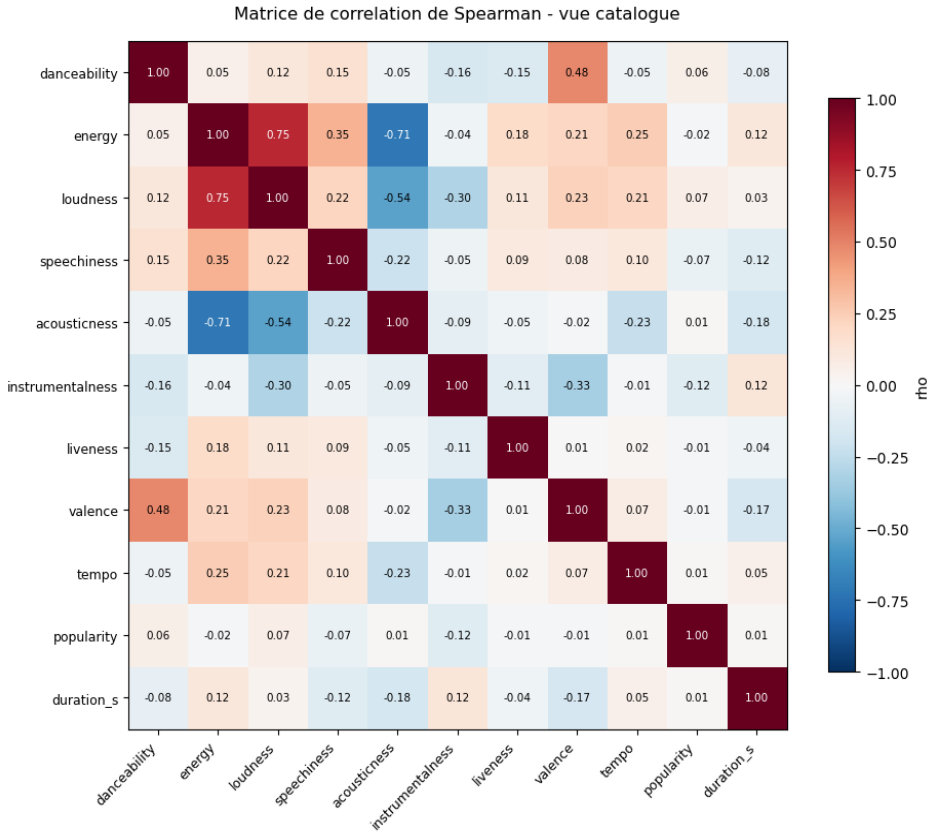
Décision

Tests non paramétriques :
Spearman plutôt que Pearson,
Kruskal-Wallis plutôt qu'ANOVA.
Ils travaillent sur les rangs.

Shapiro-Wilk devient inexploitable au-delà de 5 000 observations : il est appliqué sur échantillons aléatoires et croisé avec un examen visuel. C'est le graphique qui décide en dernier ressort, pas la p-value.

QUANTITATIF × QUANTITATIF · SPEARMAN

Test 1 — Les caractéristiques audio sont-elles liées ?



À 90 000 observations, la p-value serait tout aussi minuscule pour ρ = 0,05 : c'est le coefficient qui fonde la conclusion, pas elle.

H_0 : aucune relation monotone entre energy et loudness. α = 0,05 · n = 89 740



ρ = 0,753

coefficient de Spearman — H_0 rejetée

56,7 %

de variance partagée

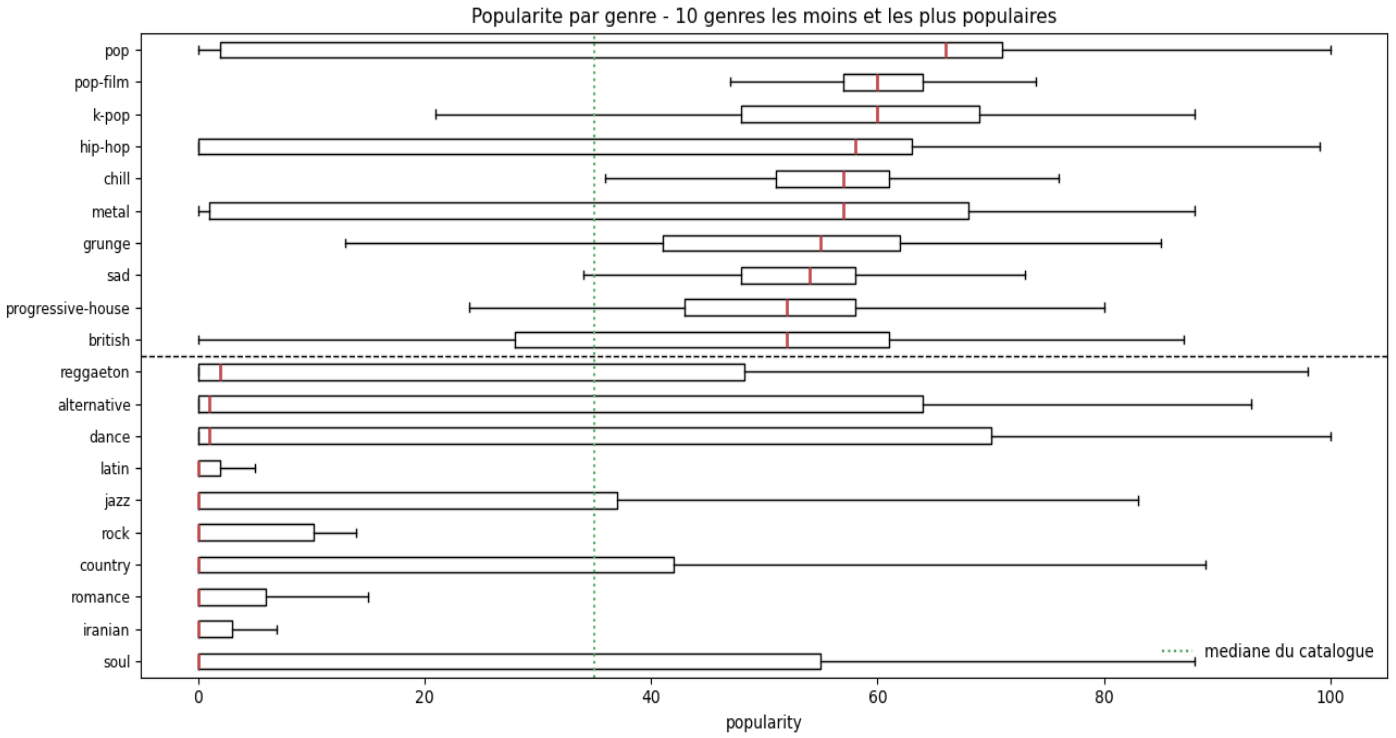
CONCLUSION MÉTIER

Oui pour quelques couples — mais la popularité n'est corrélée à aucune variable audio.

Chercher le hit par optimisation de la danceability ou de l'énergie est une impasse. Le levier n'est pas sonore.

QUALITATIF × QUANTITATIF · KRUSKAL-WALLIS

Test 2 — La popularité diffère-t-elle selon le genre ?



Médiane 0 pour country, 66 pour pop. H_0 : la popularité suit la même distribution dans les 114 genres.

CONCLUSION MÉTIER **Le positionnement de genre est un levier réel — contrairement au réglage des paramètres audio.**

Résultat du test

H = 30 955 · p < 0,001 → H_0 rejetée.
L'ANOVA était exclue faute de normalité.

Taille d'effet

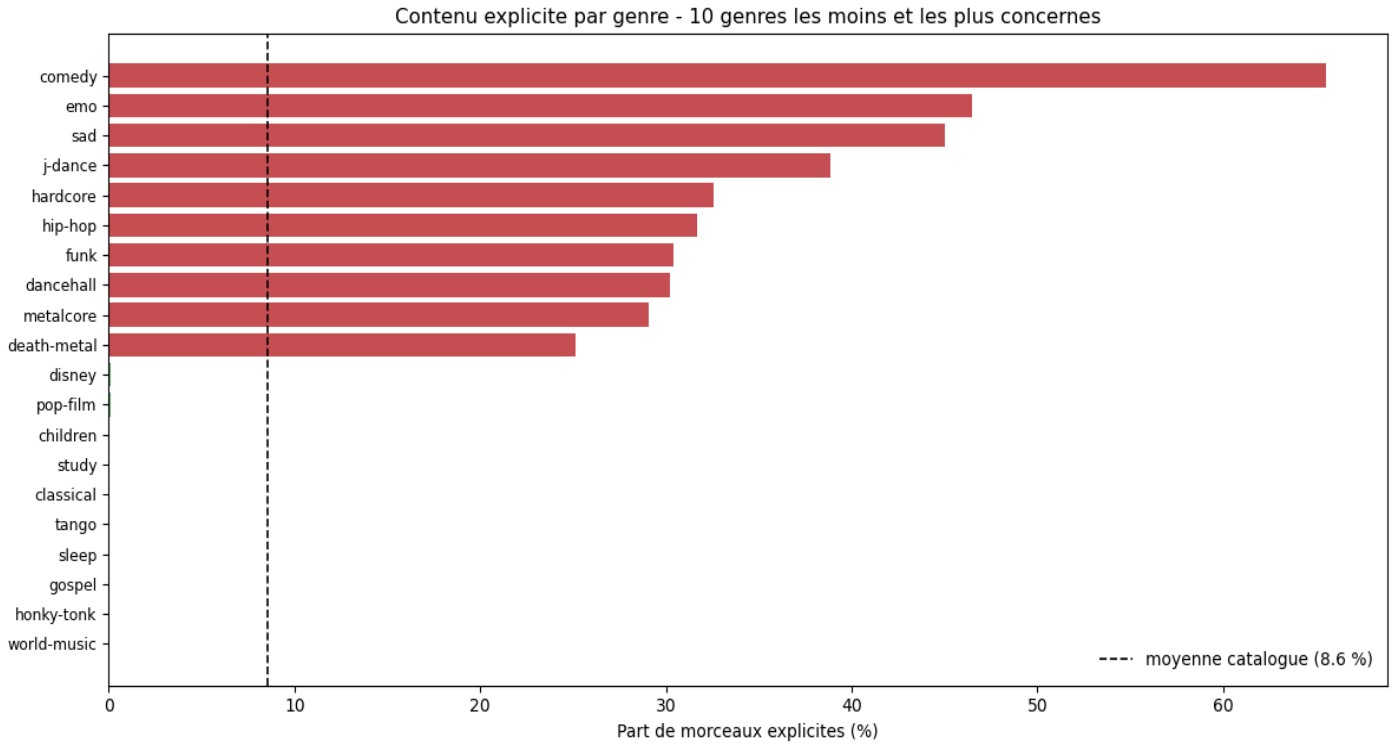
ε^2 = 0,272 → le genre explique 27,2 % de la variabilité.

La réserve à formuler

Les zéros ne sont pas répartis au hasard : 68 % des morceaux jazz sont à 0, contre 0 % pour comedy. Une part de l'écart tient à la couverture des écoutes, pas au succès.

QUALITATIF × QUALITATIF · X^2 D'INDÉPENDANCE

Test 3 — Le contenu explicite dépend-il du genre ?



H_0 : le caractère explicite est indépendant du genre. Moyenne du catalogue en pointillés.

CONCLUSION MÉTIER **Résultat directement actionnable : filtrage parental, distribution radio, playlists sous contrainte.**

Résultat du test

$\chi^2 = 18\,362$ · 113 ddl · $p < 0{,}001$
→ H_0 rejetée.

Taille d'effet

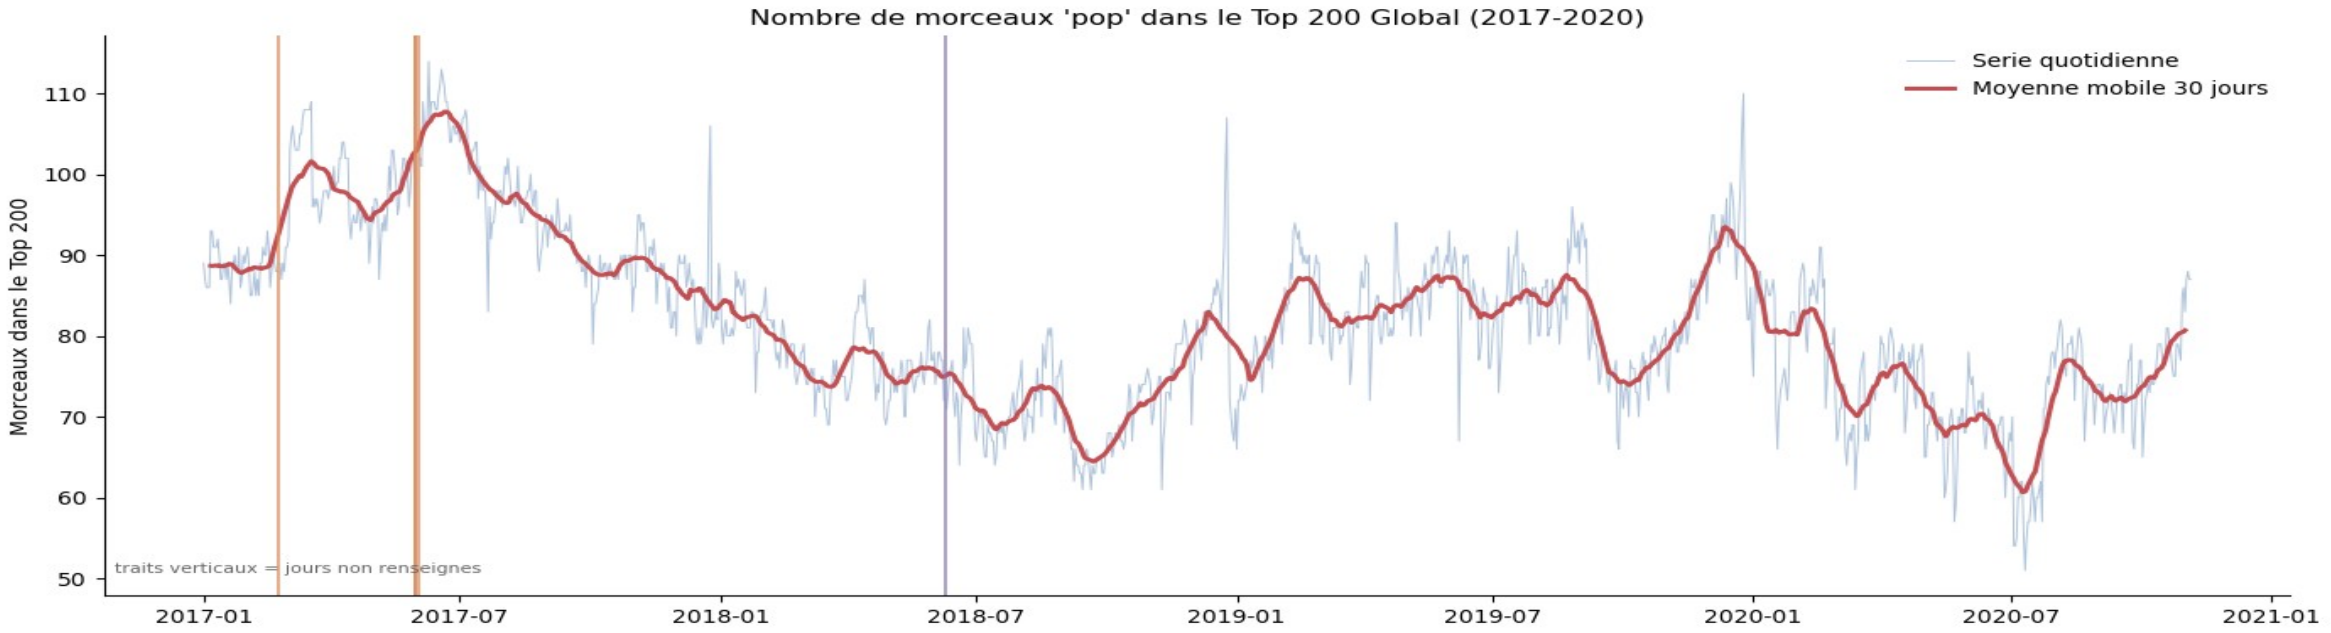
V de Cramér = 0,402 — association forte.

Conditions vérifiées

Effectif théorique minimal : 77,4, très au-dessus du seuil de 5 exigé. Le test est valide.

MISSION 2 — ÉTAPE 4

De 9,8 millions de lignes à 1 405 points



94,1 → 73,7

morceaux/jour, de 2017 à 2020 — avec un rebond en 2019

5

discontinuités : 4 dates absentes + 1 collecte corrompue, traitées en NaN

0

vrai zéro : la Pop n'a jamais quitté le Top 200

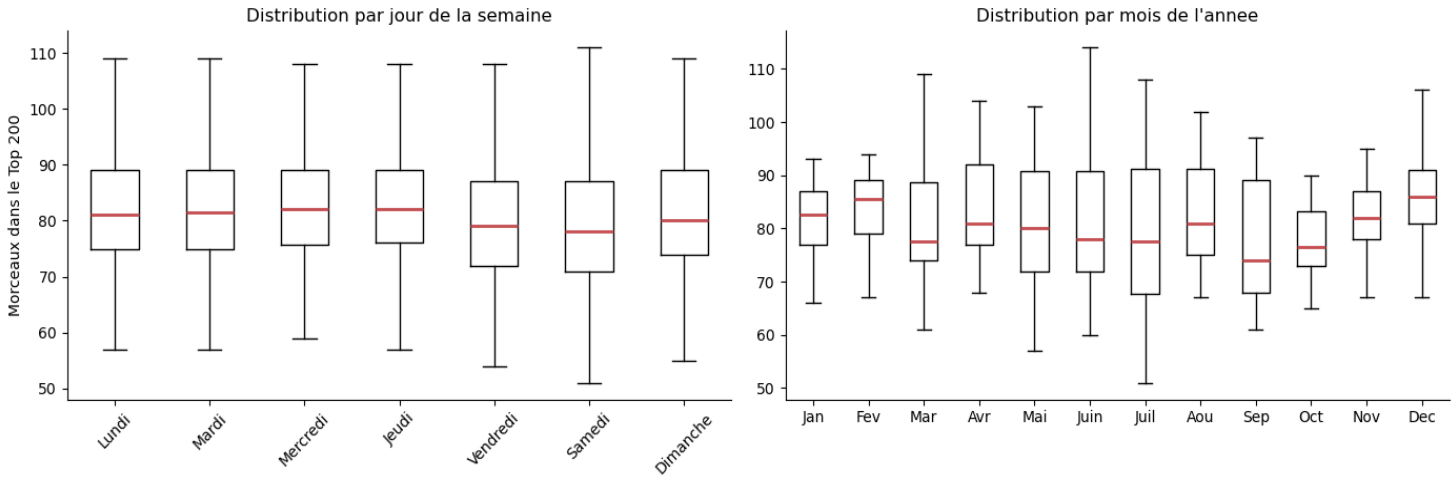
40,8 %

part de la Pop dans le Top 200 Global

Prophet modélise une série univariée : l'agrégation n'est pas une simplification, c'est la construction de l'objet d'analyse. · Les jours vides sont des trous de collecte, prouvés par l'absence simultanée des 35 marchés : un 0 aurait appris au modèle un effondrement qui n'a jamais eu lieu.

MISSION 2 — SAISONNALITÉ HEBDOMADAIRE

Le vendredi est un creux, pas un pic



Le résultat mesuré

Vendredi 79,9 et samedi 79,6 morceaux, contre 82,9 en milieu de semaine.

L'attendu était l'inverse

Le vendredi est le jour traditionnel de sortie des nouveautés : on attendrait un pic.

L'EXPLICATION

Le Top 200 est un classement à taille fixe. Le vendredi, les nouveautés affluent tous genres confondus et chaque entrée expulse un titre. La Pop, qui occupe 40 % du classement, cède des places par simple effet de masse.

Recommandation directe : éviter de caler une sortie Pop majeure un vendredi.

MISSION 2 — ÉTAPE 5

Évaluer honnêtement : trois exigences

1

Ne jamais juger sur des données vues

La période de test est strictement postérieure à l'entraînement. Un tirage aléatoire laisserait le modèle lire l'avenir.

2

Ne pas choisir et juger sur le même jeu

Comparer des configurations sur le test le disqualifie comme test. J'ai donc réglé le modèle par validation croisée sur 9 origines successives.

3

Se comparer à une référence simple

« 7 morceaux d'erreur », est-ce beaucoup ? Un modèle naïf — reproduire la dernière semaine — donne l'échelle.

Deux échecs assumés, et ce qu'ils ont appris

Échec 1 — la configuration par défaut

Prophet estime le motif annuel avec 20 paramètres à partir de moins de 4 cycles : il fabrique une saisonnalité et la rejoue.
Erreur 18,24, couverture de l'intervalle 6,7 %.

ÉCHEC 2 — LE RÉGLAGE SUR UNE FENÊTRE UNIQUE

La meilleure de 72 configurations battait le naïf de 2 %. À ce niveau, on sélectionne du hasard, pas de la qualité.

Sur le test, l'erreur passe de 5,73 à 14,66 — et la prévision annonçait 119,7 morceaux/jour, un record jamais atteint en 4 ans.

MISSION 2 — ÉTAPE 5

Le verdict sur la période de test

Modèle	MAE	RMSE	MAPE	|biais| / MAE	Couverture 95 %
Naïf saisonnier (7 jours)	4,92	5,78	6,7 %	0,77	—
Prophet — configuration par défaut	18,24	19,49	23,9 %	1,00	6,7 %
Prophet — réglé sur fenêtre unique	14,66	15,33	19,2 %	1,00	14,4 %
Prophet — tendance plate (retenu)	7,41	8,11	10,1 %	0,92	100 %

Le modèle retenu se trompe en moyenne de 7,4 morceaux par jour, soit 10 % de la valeur réelle. Configuration : tendance plate, sans saisonnalité annuelle — sur 21 configurations testées, seules 3 tenaient le critère de couverture, toutes à tendance plate.

LA CONCLUSION À ASSUMER

Le modèle naïf reste devant.

Établi sur 9 fenêtres de validation croisée, puis confirmé par le test indépendant. La meilleure prévision à 6 mois est le niveau courant, assorti d'une fourchette large.

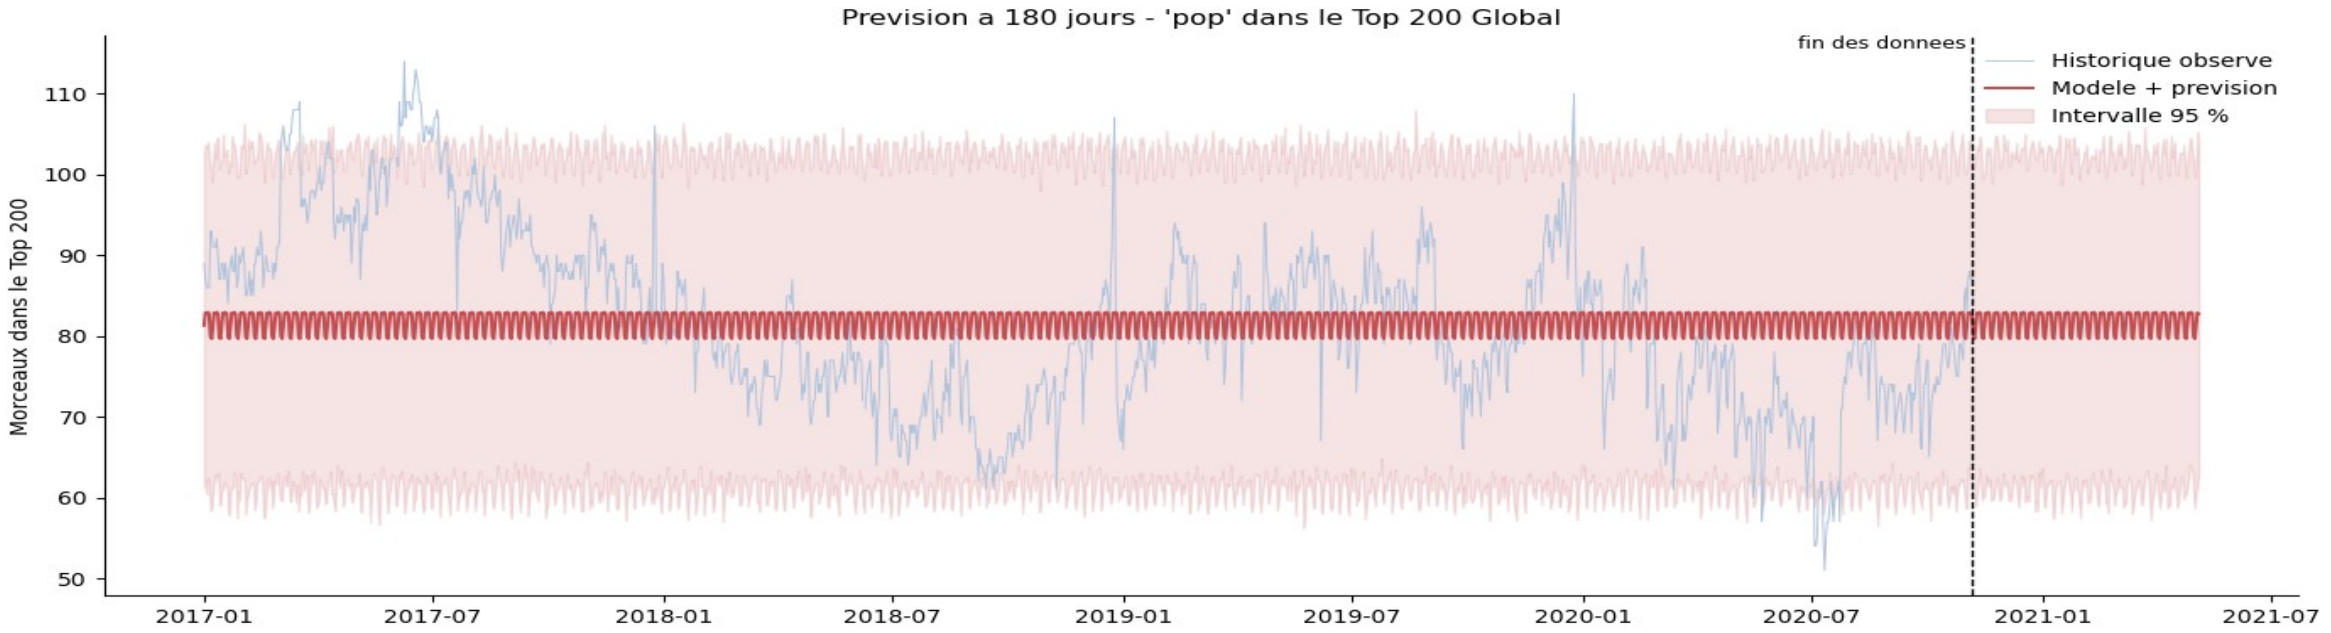
Ce que Prophet apporte malgré tout

- Des intervalles correctement calibrés : 95,6 % en validation croisée, exactement la valeur nominale
- Une décomposition interprétable en tendance et saisonnalités

Le modèle naïf ne donne ni l'un ni l'autre.

MISSION 2 — RÉSULTAT

La prévision à 6 mois



81,6
morceaux/jour prévus en moyenne

61 – 102
intervalle de confiance à 95 %

79,2
niveau observé sur les 30 derniers jours

+3,2 %
évolution attendue sur l'horizon

51 – 114
enveloppe historique — la prévision y reste

Le message aux labels est une fourchette, jamais un chiffre unique : entre 61 et 102 morceaux Pop dans le Top 200 Global, avec une valeur centrale proche du niveau actuel.

MISSION 2 — LIMITES

Ce que la prévision ne peut pas dire

Continuité des motifs passés

Prophet prolonge ce qu'il a observé. Un changement d'algorithme Spotify ou l'irruption d'un genre ne figurent dans aucune donnée.

Fiabilité décroissante

L'erreur a été mesurée sur 90 jours. À 180 jours, elle sera supérieure : c'est un plancher, pas un plafond.

Aucune explication causale

La prévision constate un mouvement sans dire au bénéfice de quel genre la Pop cède du terrain.

Intervalle à largeur constante

Contrepartie de la tendance plate : l'incertitude ne s'élargit pas avec l'horizon, alors qu'elle le devrait.

2020 dans l'entraînement

Année atypique pour l'industrie : le modèle a partiellement appris un régime exceptionnel.

Une place, pas des écoutes

Le Top 200 est à taille fixe : perdre des places, c'est céder du terrain en relatif, pas reculer en absolu.

Et un septième point, sur la cadence mensuelle de sortie

La collecte s'arrête fin 2020, or un morceau n'entre au fichier des sorties que s'il a atteint les classements : les titres récents n'en ont pas eu le temps. La série est artificiellement rabotée sur sa fin. → Lecture qualitative uniquement, aucun chiffre communiqué aux labels.

SYNTHÈSE

Recommandations pour les labels

Recommandation	Fondement	Source
Ne pas chercher le hit par optimisation des paramètres audio	La popularité n'est corrélée à aucune variable audio	M1 — Spearman
Travailler le positionnement de genre plutôt que le réglage sonore	Le genre explique 27,2 % de la variabilité de la popularité	M1 — Kruskal-Wallis
Exploiter les taux d'explicite par genre pour le filtrage et la distribution	Association forte entre genre et contenu explicite (V = 0,402)	M1 — χ^2
Éviter de caler une sortie Pop majeure un vendredi	Concurrence maximale des nouveautés dans un classement à taille fixe	M2 — saisonnalité
Communiquer une fourchette, jamais un chiffre unique	L'incertitude s'élargit avec l'horizon ; un chiffre isolé donne une fausse précision	M2 — prévision
Réactualiser le modèle chaque trimestre, réglage compris	L'hypothèse de continuité se dégrade avec le temps	M2 — méthode
Ne pas chiffrer la cadence de sortie	Biais de troncature non corrigeable avec les données disponibles	M2 — étape 6

Prolongement immédiat : réexécuter l'analyse sur rap, latin et hip hop — un seul paramètre à changer. C'est ce qui dirait au bénéfice de quel genre la Pop cède du terrain, la seule question que ce travail pose sans y répondre.

CE QUE JE RETIENS

Un résultat négatif documenté vaut mieux qu'un chiffre flatteur non vérifié.

Le nettoyage n'est pas un préalable, c'est une analyse

Doublons stricts contre multi-genres, jours absents contre vrais zéros : deux pièges qui auraient faussé tout l'aval.

Une métrique sans référence ne se juge pas

Sans le modèle naïf, une erreur de 7 morceaux par jour aurait été présentée comme un succès.

Choisir et juger demandent deux jeux distincts

Le réglage sur une fenêtre unique a produit une prévision à 119,7 morceaux — jamais atteinte en 4 ans.

La p-value ne remplace pas la taille d'effet

À 90 000 observations, tout devient significatif. Seule l'intensité de la relation permet de conclure.